深度学习基础实验1：FNN回归任务实验报告

PB23111684 黄泽辉

一、 实验目的与数据集说明

- **实验目的**：构建前馈神经网络（FNN）完成回归任务，并探究网络深度、学习率和激活函数对模型性能的影响
- **数据集**：本实验使用糖尿病疾病进展数据集（Diabetes dataset），包含442个样本，每个样本有10个医学特征。10个输入特征均为数值型且已进行标准化处理，目标为预测疾病进展指标（连续值）
- **数据划分**：将数据集随机划分为训练集、验证集和测试集，本次实验的实际样本划分情况为：训练集 282 个、验证集 71 个、测试集 89 个（按照4:1划分）

二、 实验环境与模型构建

- **模型结构**：构建输入层维度为10，输出层为1个神经元的前馈神经网络。
- **训练配置**：
  - **损失函数**：均方误差（MSE）
  - **优化器**：Adam优化器
  - **批量大小**：16
  - **训练策略**：总计训练 1000 个 Epoch，每个epoch输出训练集和验证集的损失，并基于验证集损失保存最佳模型参数，最后在测试集上评估模型性能并计算测试损失

三、 实验结果与分析

3.1 网络深度的影响

1. 实验设置：

- 固定学习率（如 0.001）
- 固定激活函数（如 ReLU）
- 设计3种网络结构：

网络类型	隐藏层数	备注
浅层网络	1个隐藏层	基础结构
中等网络	2个隐藏层	常用结构
深层网络	3个隐藏层	较深结构

2. 实验结果图示

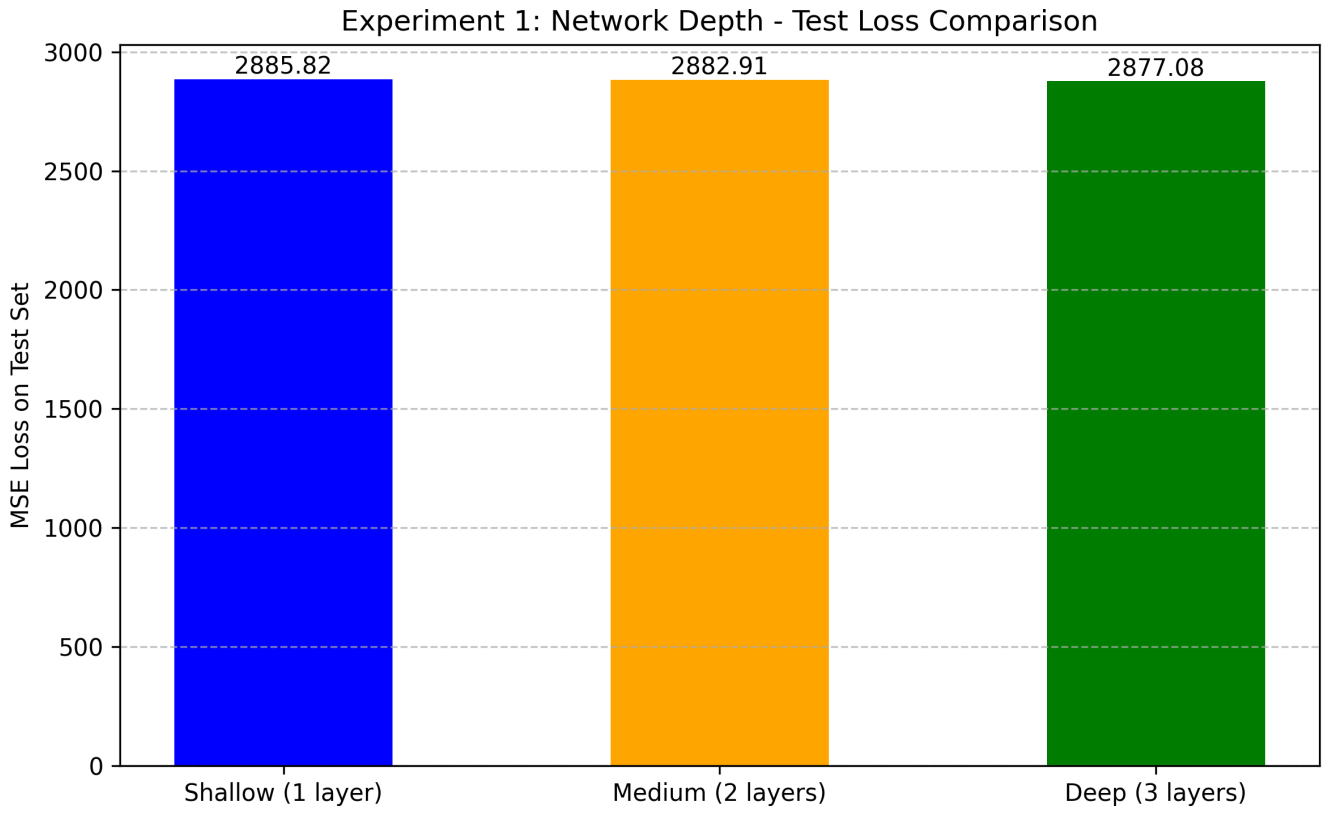
Experiment 1: Network Depth - Test Loss Comparison
MSE Loss on Test Set
3000
2500
2000
1500
1000
500
0
2885.82
2882.91
2877.08
Shallow (1 layer)
Medium (2 layers)
Deep (3 layers)

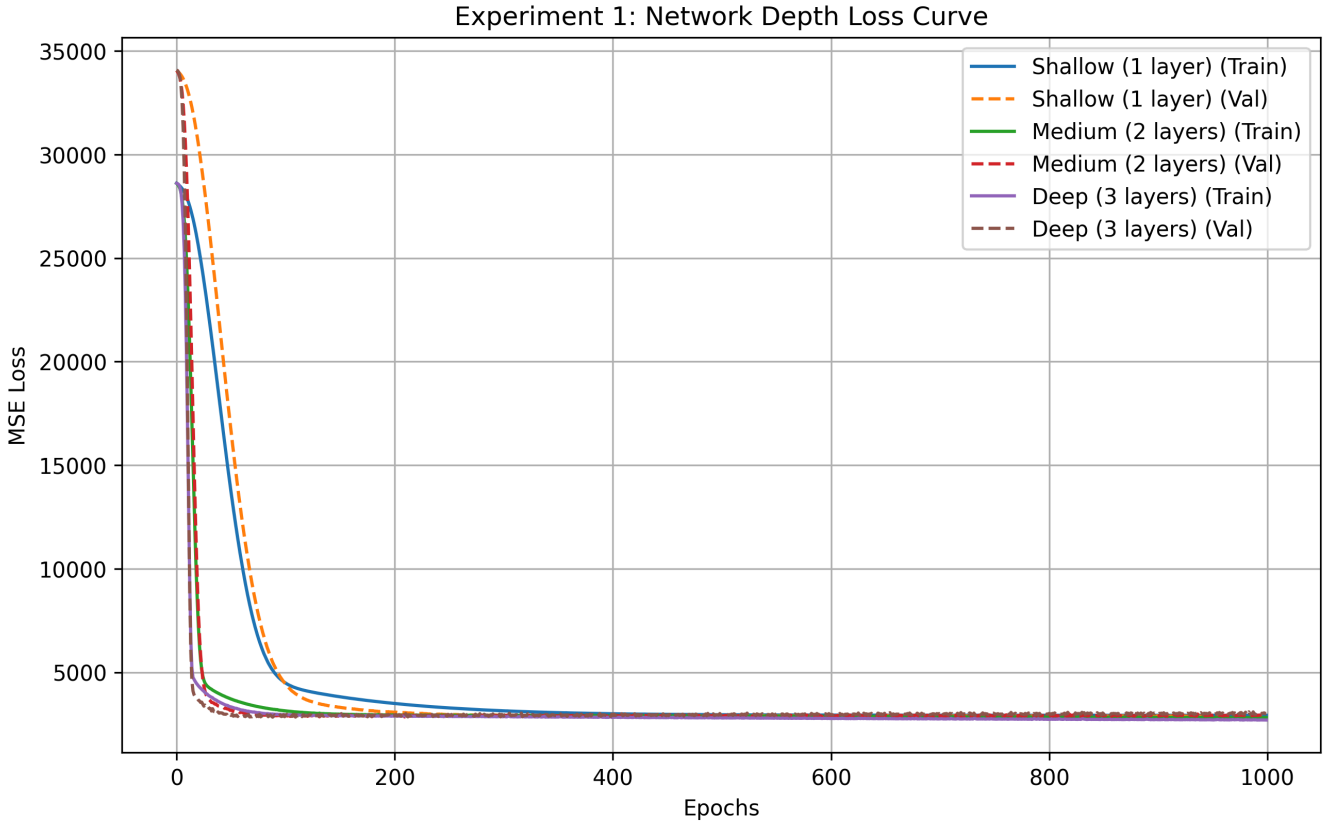
Experiment 1: Network Depth Loss Curve
MSE Loss
35000
30000
25000
20000
15000
10000
5000
0
200
400
600
800
1000
Epochs
Shallow (1 layer) (Train)
Shallow (1 layer) (Val)
Medium (2 layers) (Train)
Medium (2 layers) (Val)
Deep (3 layers) (Train)
Deep (3 layers) (Val)

3. 结果对比与分析

- 从损失曲线可以看出，在 1000 个 Epoch 的充足训练下，三种深度的网络均能良好收敛。深层网络在训练初期的下降速度最快
- 最终的测试集表现非常接近：浅层网络 (2885.82)、中等网络 (2882.91)、深层网络 (2877.08)
- **结论**：对于该规模较小的数据集，在给予足够训练时间（1000 Epochs）的前提下，网络深度的增加带来的性能提升非常微弱（MSE差异在10以内）。考虑到计算成本，浅层或中等网络已足以胜任此任务

3.2 学习率的影响

1. 实验设置：

- 固定网络结构（如2层隐藏层）
- 固定激活函数（如 ReLU）
- 测试学习率：0.1、0.01、0.001、0.0001

2. 实验结果图示

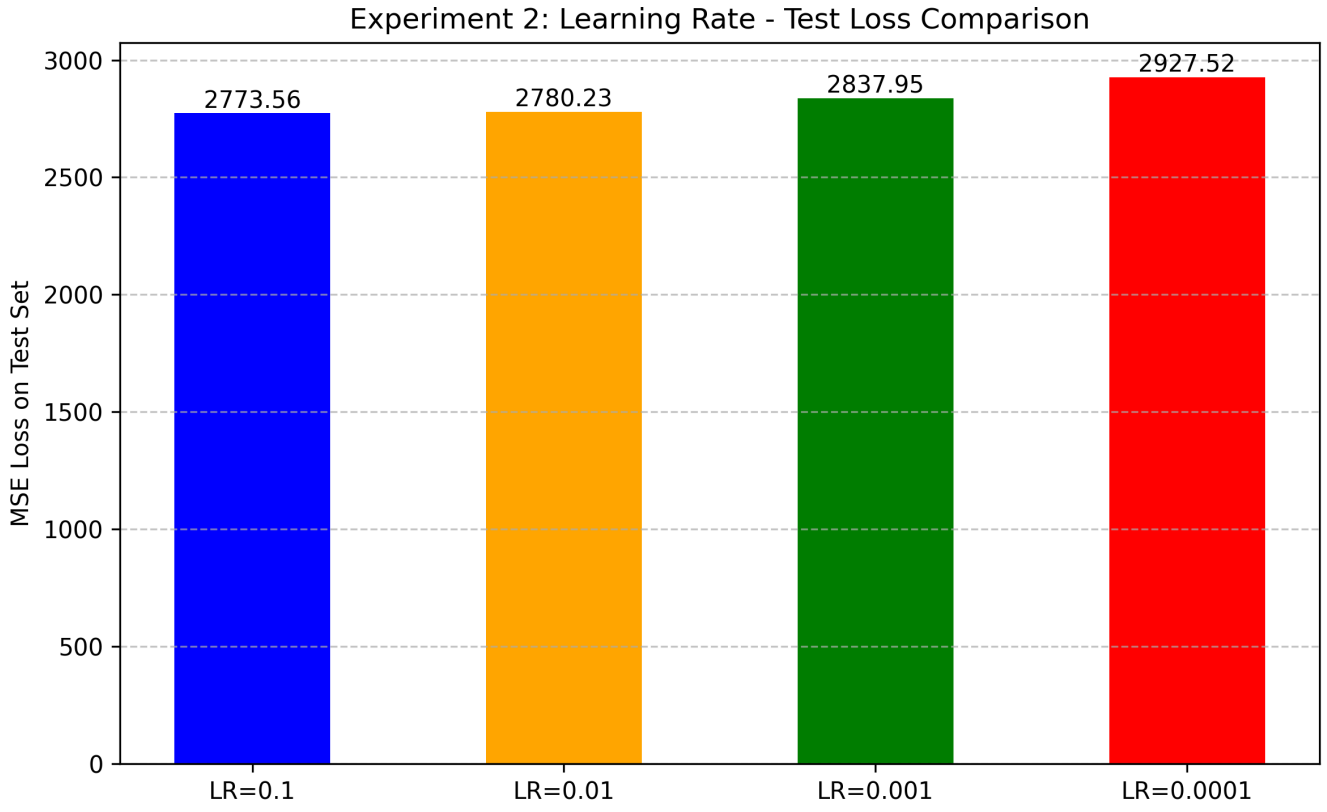

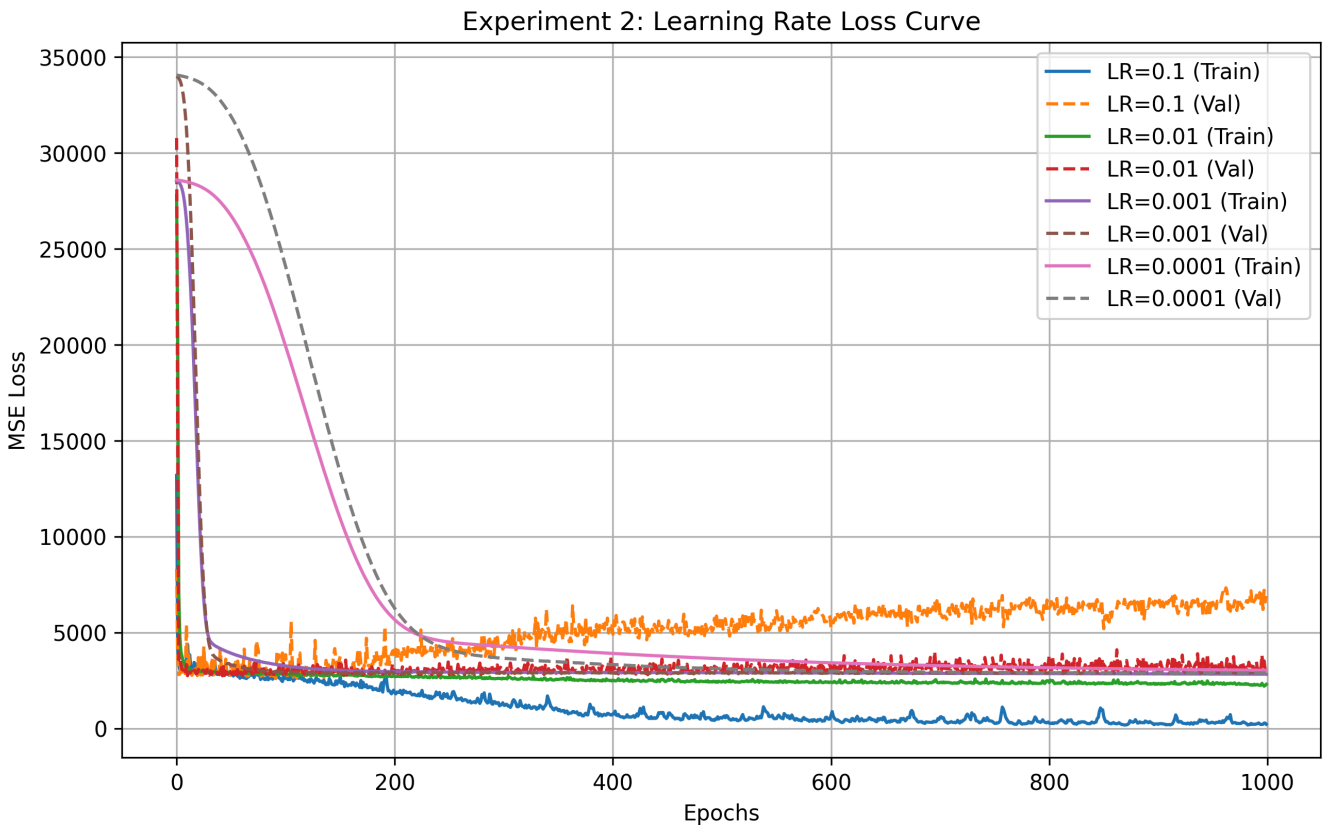

3. 结果对比与分析

- **LR = 0.1 (2773.56)**：虽然最终获得了最低的测试集 Loss，但观察曲线发现，其训练和验证损失在整个过程中伴随剧烈震荡，模型处于极度不稳定的状态
- **LR = 0.01 (2780.23)**：收敛速度极快，最终性能优异，但曲线中后期依然存在明显的波动噪声
- **LR = 0.001 (2837.95)**：曲线最为平滑稳定，没有明显的震荡现象，虽然最终 Loss 略高于前两者，但它是最稳健的训练选择
- **LR = 0.0001 (2927.52)**：学习率过小，导致收敛极其缓慢，哪怕经过了 1000 个 Epoch，其 Loss 依然是四组中最高的
- **结论**：较大的学习率可能偶然达到较低的 Loss，但牺牲了训练的稳定性；0.001 是在收敛速度和稳定性之间取得最佳平衡的超参数

3.3 激活函数的影响

1. 实验设置：

- 固定网络结构（2层隐藏层）
- 固定学习率（0.001）
- 测试激活函数：Sigmoid、Tanh、ReLU、LeakyReLU、Swish

2. 实验结果图示

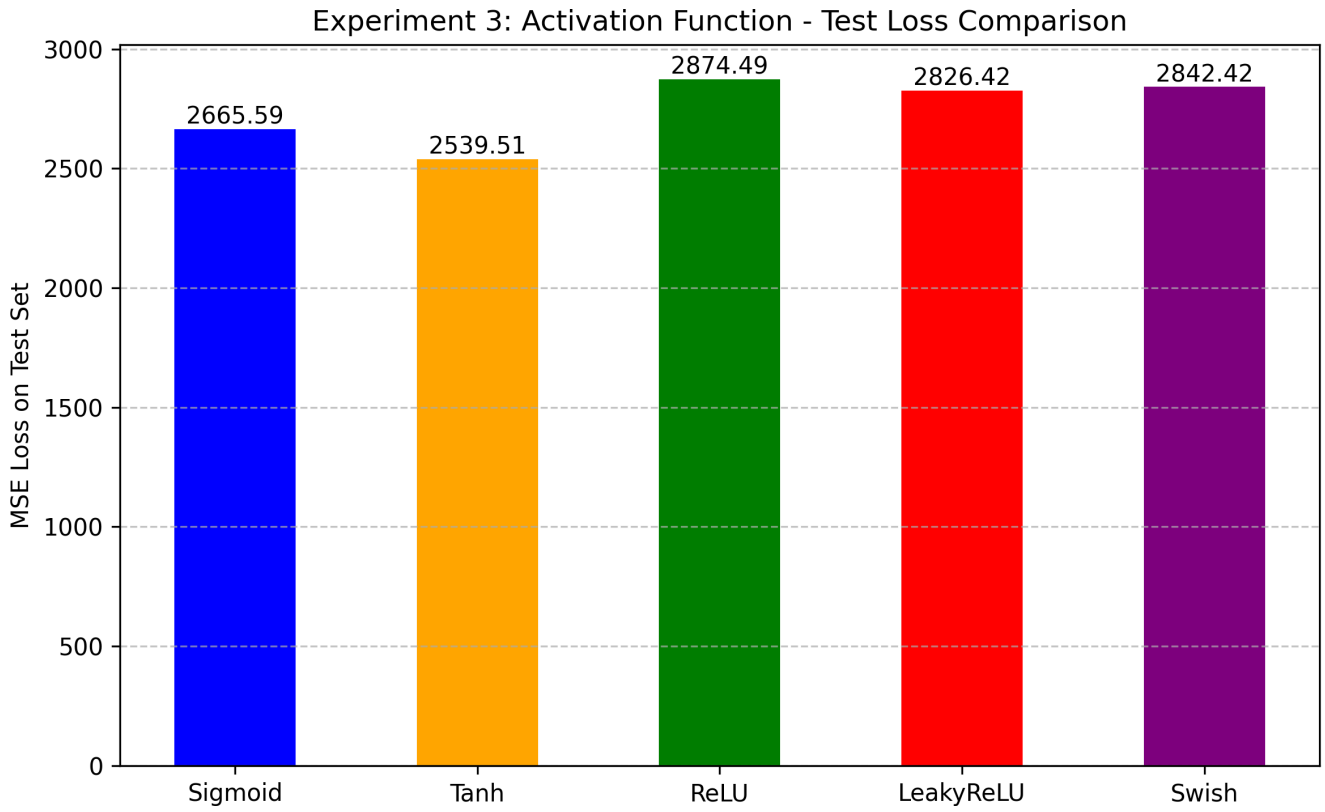
Experiment 3: Activation Function - Test Loss Comparison
MSE Loss on Test Set
3000
2500
2000
1500
1000
500
0
2665.59
2539.51
2874.49
2826.42
2842.42
Sigmoid
Tanh
ReLU
LeakyReLU
Swish

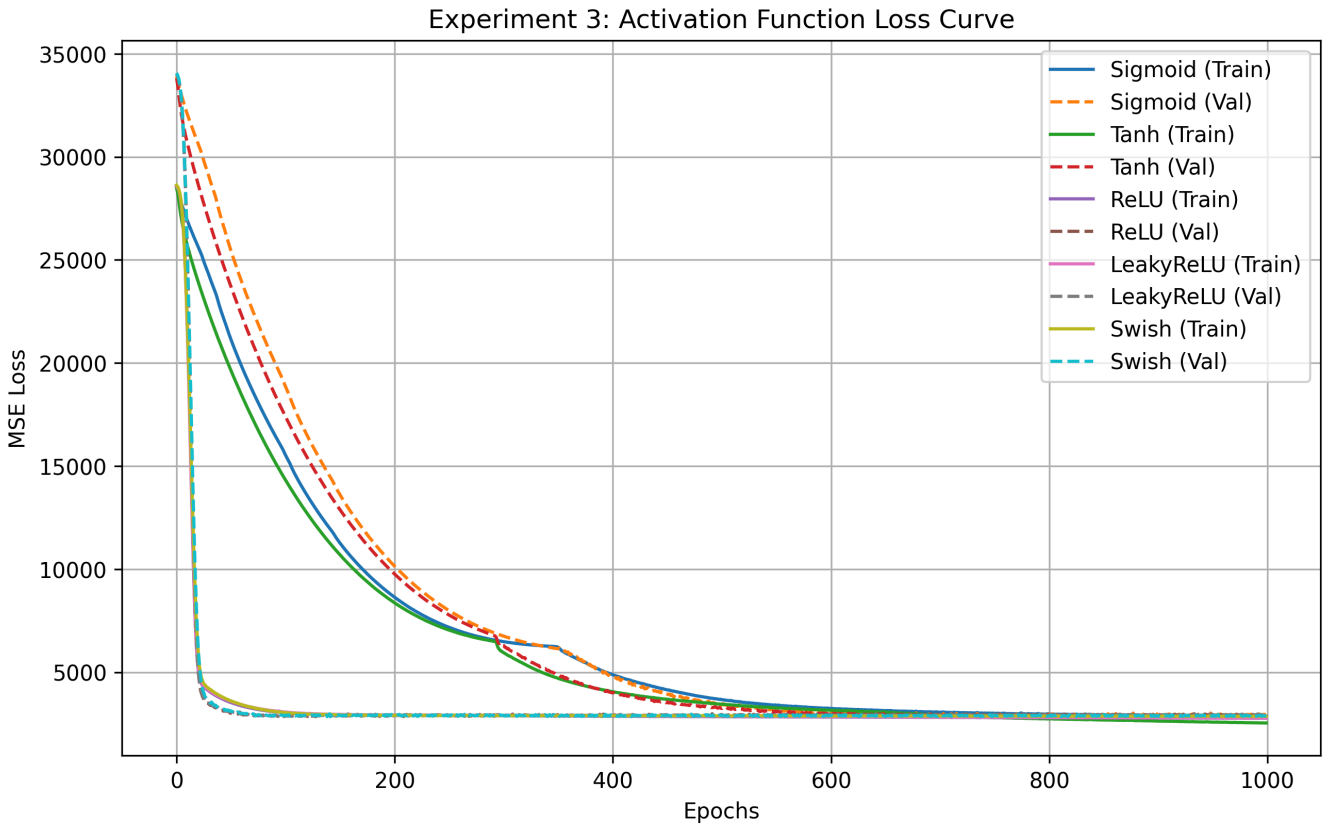
Experiment 3: Activation Function Loss Curve
MSE Loss
35000
30000
25000
20000
15000
10000
5000
0
200
400
600
800
1000
Epochs
Sigmoid (Train)
Sigmoid (Val)
Tanh (Train)
Tanh (Val)
ReLU (Train)
ReLU (Val)
LeakyReLU (Train)
LeakyReLU (Val)
Swish (Train)
Swish (Val)

3. 结果对比与分析

- **收敛速度对比**：从曲线图可以明显看到，ReLU类函数（ReLU、LeakyReLU、Swish）在最初的几十个 Epoch 内就完成了快速下降；而 Sigmoid 和 Tanh 在前 300 个 Epoch 左右陷入了明显的停滞期，之后才开始大幅下降
- **最终性能对比**：前期表现迟缓的 Tanh (2539.51) 和 Sigmoid (2665.59) 在 1000 个 Epoch 后实现了反超，取得了比 ReLU类函数（均在 2820-2870 之间）更低的最终测试集 Loss
- **结论**：ReLU 及其变体能有效解决梯度消失问题，极大地提升了训练初期的收敛速度；但对于本数据集，传统的饱和型激活函数（Tanh/Sigmoid）在克服了前期的“启动困难”后，展现出了更好的拟合能力

四、 实验总结

通过本次端到端的深度学习回归实验，得出以下结论：

1. **网络深度需适度**：对于特征维度仅为 10 的数据集，盲目增加网络层数并不能带来显著的性能飞跃，反而可能增加模型复杂度和训练时间
2. **学习率的权衡**：学习率的选择是收敛速度与稳定性的博弈。过大的学习率容易导致损失震荡不收敛，过小则收敛缓慢
3. **激活函数的影响：**Sigmoid和Tanh函数在训练初期容易产生梯度消失的问题，前期权重更新缓慢，而ReLU类函数能有效解决这种问题，极大的提高了训练初期的的收敛速度。不过对于本次实验室用的数据集，在1000个Epoch的训练下，Sigmoid和Tanh在度过前期的“启动困难”后，展现出了更好的拟合能力